

BNPL BIG DATA PLATFORM

TÀI LIỆU THIẾT KẾ VÀ KẾ HOẠCH TRIỂN KHAI

Big Data Analytics and Credit Risk Prediction in Buy Now, Pay Later Services

Cập nhật: 18/09/2026

Tóm tắt tài liệu

Tài liệu này tổng hợp và chuẩn hóa toàn bộ phạm vi đã thống nhất cho đề án cuối môn Big Data về phân tích dữ liệu và dự đoán rủi ro tín dụng trong dịch vụ Buy Now, Pay Later (BNPL). Định hướng cốt lõi là xây dựng một nền tảng Big Data hoàn chỉnh trước; Machine Learning được xem là một downstream use case trên nền dữ liệu đã được ingestion, kiểm tra chất lượng, chuẩn hóa và mô hình hóa.

Hệ thống hỗ trợ đồng thời hai luồng: batch processing cho dữ liệu lịch sử và streaming processing cho giao dịch BNPL mới được giả lập. Dữ liệu lịch sử được xử lý qua Medallion Architecture (Bronze, Silver, Gold), phục vụ BI/Analytics và huấn luyện mô hình. Các giao dịch mới được phát sinh từ fake data generator, truyền qua Apache Kafka và được Apache Spark Structured Streaming xử lý để thực hiện dự đoán rủi ro default trong 30 ngày và 90 ngày gần thời gian thực.

Nguyên tắc thiết kế chính

Big Data Platform first, Machine Learning downstream. Mỗi công nghệ phải có vai trò rõ ràng trong kiến trúc; không mở rộng scope chỉ để tăng số lượng công nghệ.

Mục lục nội dung

- 1. Bối cảnh và bài toán
- 2. Dataset và phạm vi dữ liệu
- 3. Mục tiêu và phạm vi hệ thống
- 4. Technology Stack
- 5. Kiến trúc tổng thể
- 6. Batch Ingestion và Streaming Ingestion
- 7. Medallion Architecture
- 8. Schema Validation và Data Quality
- 9. Incremental Processing và Idempotency
- 10. Gold Analytics và Star Schema
- 11. Gold ML và Feature Engineering
- 12. Machine Learning 30D / 90D
- 13. Streaming Prediction với Kafka
- 14. Airflow Orchestration
- 15. PostgreSQL và Power BI
- 16. Spark Cluster và Big Data Benchmark
- 17. Docker Architecture và cấu trúc repository

- 18. Thứ tự triển khai
- 19. Kịch bản demo cuối môn
- 20. Deliverables, Definition of Done và giới hạn

1. Bối cảnh và bài toán

1.1. Bối cảnh

Buy Now, Pay Later (BNPL) là mô hình thanh toán cho phép khách hàng nhận hàng trước và thanh toán theo kỳ hoặc sau một khoảng thời gian. Ở góc nhìn dữ liệu, hệ thống BNPL phát sinh khối lượng lớn giao dịch, thông tin khách hàng, thông tin merchant, khoản vay, lãi suất, kỳ hạn và kết quả thanh toán. Đây là bối cảnh phù hợp để xây dựng một hệ thống Big Data có khả năng ingestion, xử lý phân tán, kiểm soát chất lượng, phân tích và phục vụ Machine Learning.

1.2. Bài toán nghiệp vụ

Đề án tập trung vào hai nhóm bài toán: (1) phân tích dữ liệu giao dịch BNPL ở quy mô lớn; (2) dự đoán rủi ro khách hàng/giao dịch có khả năng default trong các khoảng thời gian 30 ngày và 90 ngày.

Problem statement ngắn gọn

Predict BNPL default risk within 30 and 90 days using binary classification.

Bài toán Machine Learning thuộc nhóm Binary Classification:

- default_30d = 0: Non-default trong 30 ngày.
- default_30d = 1: Default trong 30 ngày.
- default_90d = 0: Non-default trong 90 ngày.
- default_90d = 1: Default trong 90 ngày.

1.3. Hai đầu ra chính của hệ thống

- Analytics: transaction volume, default rate, provider analysis, merchant analysis, geographic analysis, credit risk analysis.
- Machine Learning: probability và classification cho default_30d và default_90d.




Figure 1: Tổng quan hai nhóm đầu ra của hệ thống: Analytics và Machine Learning.

2. Dataset và phạm vi dữ liệu

2.1. Dataset chính

Nguồn dữ liệu chính là dataset BNPL Nigeria trên Hugging Face: [electricsheepafrica/africa-synth-banking-bnpl-nigeria](#). Dataset ở định dạng Parquet, có khoảng 2 triệu bản ghi giao dịch và được gán cho các bài toán tabular classification/regression. Dữ liệu là synthetic data, do đó kết quả đồ án được dùng để đánh giá kiến trúc và phương pháp xử lý/mô hình hóa, không được xem là kết luận thực nghiệm về toàn bộ thị trường BNPL Nigeria.

Nhóm	Trường dữ liệu chính
Định danh	transaction_id, customer_id
Thời gian	purchase_date, first_payment_due
Merchant	merchant_name, merchant_category
Địa lý	customer_state
Khoản vay	principal_ngn, interest_rate_monthly, tenor_days, num_installments
Provider	provider
Khách hàng	credit_score, first_time_customer
Target	default_30d, default_90d

Grain của dataset:

Grain

1 record = 1 BNPL transaction.

2.2. Vai trò dữ liệu lịch sử và dữ liệu streaming

Historical dataset chứa các target default_30d và default_90d nên được sử dụng để phân tích và huấn luyện mô hình. Ngược lại, giao dịch streaming giả lập chỉ chứa thông tin có thể biết tại thời điểm giao dịch. Streaming event không được chứa default_30d hoặc default_90d vì hai biến này là kết quả tương lai cần dự đoán.




Figure 2: Phân biệt historical data dùng cho training và streaming transaction dùng cho inference.

3. Mục tiêu và phạm vi hệ thống

3.1. Mục tiêu tổng quát

Xây dựng một BNPL Big Data Platform end-to-end có khả năng tiếp nhận dữ liệu lịch sử và dữ liệu streaming, lưu trữ trên Data Lake, xử lý phân tán bằng Spark, áp dụng Data Quality, tạo Data Warehouse phục vụ BI, tạo ML Feature Table, huấn luyện mô hình và thực hiện near-real-time prediction.

3.2. Các năng lực bắt buộc

- Historical batch ingestion.
- Streaming ingestion bằng Apache Kafka.
- Medallion Architecture: Bronze / Silver / Gold.
- Distributed processing bằng Apache Spark / PySpark / Spark SQL.
- Schema Validation và controlled schema evolution.

- Data Quality Gate, rejected records và Data Quality Monitoring.
- Incremental processing và idempotent pipeline.
- Gold Analytics + Star Schema + PostgreSQL.
- Power BI serving.
- Gold ML Feature Table.
- Binary classification cho default_30d và default_90d.
- Near-real-time prediction cho fake BNPL transactions.
- Airflow orchestration cho batch pipeline.
- Spark scalability benchmark và full-vs-incremental benchmark.

3.3. Scope discipline

Không đưa thêm các công nghệ sau nếu không phát sinh yêu cầu kỹ thuật thực sự:

- Apache Flink
- Kubernetes
- Elasticsearch / OpenSearch
- Terraform
- Databricks
- RAG / LLM / Agent

Nguyên tắc phạm vi

Depth > breadth. Một pipeline chạy end-to-end, giải thích được và benchmark được có giá trị hơn một hệ thống chứa nhiều công nghệ nhưng thiếu chiều sâu.

4. Technology Stack

Thành phần	Công nghệ	Vai trò
Processing	Apache Spark / PySpark / Spark SQL	Xử lý phân tán batch và transformation.
Streaming	Apache Kafka + Spark Structured Streaming	Ingestion và xử lý giao dịch mới.
Data Lake	MinIO	Object storage cho Bronze/Silver/Gold.
Bronze format	Parquet	Raw persistence, đơn giản và tối ưu lưu trữ.

Silver/Gold format	Delta Lake	Schema enforcement, MERGE, incremental, versioning.
Orchestration	Apache Airflow	Schedule, dependency, retry, logging cho batch pipeline.
Warehouse/Serving	PostgreSQL	Serving cho BI, metrics, predictions, metadata.
Visualization	Power BI	Dashboard phân tích và theo dõi prediction.
Machine Learning	Spark MLlib	Training và evaluation classification.
Infrastructure	Docker / Docker Compose	Đóng gói và triển khai local reproducible.
Development	Python / SQL / Git	Code, query, version control.

5. Kiến trúc tổng thể

Hệ thống được chia thành hai data path nhưng hội tụ tại Data Lake. Historical dataset đi theo batch path, trong khi fake transaction đi qua Kafka và Spark Structured Streaming. Cả hai đều được persist vào Bronze trước khi tiếp tục qua validation, Silver và Gold.




Figure 3: Kiến trúc tổng thể BNPL Big Data Platform: Batch + Streaming + Medallion + Analytics + ML.

Nguyên tắc vai trò các thành phần:

Thành phần	Câu hỏi nó trả lời
Kafka	Dữ liệu sự kiện mới đi vào hệ thống như thế nào?
Bronze	Raw data được lưu bền vững ở đâu?
Spark	Dữ liệu lớn được xử lý như thế nào?
Delta Lake	Làm sao kiểm soát schema, incremental merge và version?
Airflow	Task nào chạy, chạy khi nào, phụ thuộc nhau ra sao?
PostgreSQL	Analytics/prediction được phục vụ cho ứng dụng/BI ở đâu?
Power BI	Người dùng quan sát insight và prediction như thế nào?

Lưu ý kiến trúc

Kafka không phải Bronze. Kafka là streaming/event transport layer; Bronze là persistent raw storage.

6. Batch Ingestion và Streaming Ingestion

6.1. Batch path

Historical BNPL dataset được ingestion vào Bronze theo batch. Airflow quản lý lịch chạy và dependency, trong khi Spark thực hiện các công việc xử lý dữ liệu lớn. Batch pipeline là nguồn chính cho analytics, model training và benchmark.




Figure 4: Batch path: Historical Dataset → Bronze → Silver → Gold → Analytics / ML Training.

6.2. Streaming path

Fake BNPL transaction generator tạo JSON event theo schema thực tế và gửi liên tục vào Kafka topic `bnpl.transactions.raw`. Spark Structured Streaming đọc topic này, parse bằng explicit schema, bảo toàn Kafka metadata và ghi raw event vào Bronze.

```

Topic chính:
bnpl.transactions.raw

Optional:
bnpl.transactions.invalid
bnpl.predictions
  
```

BNPL Big Data Platform Streaming Data Ingestion Path




Figure 5: Streaming ingestion: Fake Generator → Kafka → Spark Structured Streaming → Bronze.

6.3. Fake data generator

Fake generator phải:

- Tạo transaction_id duy nhất.
- Sinh giá trị phù hợp với domain/range của historical dataset.
- Cho phép cấu hình event rate.
- Không chứa default_30d/default_90d.
- Có thể tùy chọn sinh một tỷ lệ nhỏ invalid event để kiểm thử Data Quality.

7. Medallion Architecture

7.1. Bronze Layer

Bronze lưu dữ liệu gần nguyên bản nhất có thể, phục vụ audit, replay và reprocessing. Không thực hiện feature engineering tại Bronze.

```
s3://bnpl-data/bronze/
├── historical_transactions/
└── streaming_transactions/
```

Metadata cho historical data:

```
_ingested_at
_source
_batch_id
_ingestion_type = batch
```

Metadata bổ sung cho streaming data:

```
_source = kafka
_ingestion_type = stream
_kafka_topic
_kafka_partition
_kafka_offset
_kafka_timestamp
```

7.2. Silver Layer

Silver đại diện cho dữ liệu trusted và standardized. Silver sử dụng Delta Lake để thuận lợi cho schema enforcement, MERGE/upsert, incremental processing và idempotent write.

- Data type casting.
- Deduplication.
- Null handling.
- Range validation.
- String normalization.
- Date normalization.
- Standardized category values.

7.3. Gold Layer

Gold được chia thành hai nhánh tách biệt:

- Gold Analytics: dữ liệu tối ưu cho BI, Star Schema, PostgreSQL.
- Gold ML: flat feature table tối ưu cho Spark MLlib.




Figure 6: Medallion Architecture: Bronze → Quality Gate → Silver → Gold Analytics / Gold ML.

8. Schema Validation và Data Quality

8.1. Data Quality Gate

Quality Gate nằm giữa Bronze và Silver. Mục tiêu là quyết định record nào đủ điều kiện đi vào Silver. Record không hợp lệ không được drop âm thầm; chúng được đưa vào rejected/quarantine area kèm nguyên nhân.

BNPL Big Data Platform

Data Quality Gate




Figure 7: Data Quality Gate: PASS → Silver; FAIL → Rejected/Quarantine.

Ví dụ validation rules:

```

transaction_id IS NOT NULL
principal_ngn > 0
interest_rate_monthly >= 0
tenor_days > 0
300 <= credit_score <= 850
default_30d IN (0,1,NULL)
default_90d IN (0,1,NULL)
  
```

NULL target được phép đối với streaming transaction vì tại thời điểm giao dịch mới, kết quả default trong 30/90 ngày chưa tồn tại.

8.2. Rejected records

Rejected record nên giữ thêm metadata:

```

_validation_status
_validation_errors
_rejected_at
_pipeline_run_id
_batch_id
  
```

8.3. Data Quality Monitoring

Data Quality Monitoring khác với Quality Gate. Quality Gate quyết định record pass/fail; Monitoring đo chất lượng toàn batch/pipeline run.

Metric	Ý nghĩa
row_count	Số record đầu vào.
null_count / null_rate	Mức độ thiếu dữ liệu.
duplicate_count / duplicate_rate	Trùng lặp theo business key.
invalid_credit_score_count	Credit score ngoài phạm vi.
invalid_principal_count	Khoản vay không hợp lệ.
invalid_date_count	Ngày sai format/range.
rejected_record_count	Số record bị quarantine.
valid_record_rate	Tỷ lệ record được chấp nhận.

8.4. Schema evolution

Schema evolution phải được kiểm soát. Hệ thống so sánh incoming schema với expected schema. Optional nullable column mới có thể được xem là compatible, trong khi việc xóa required column hoặc thay đổi incompatible type được xem là breaking change.




Figure 8: Controlled schema evolution: Compare → Compatible → Evolve; Breaking → Reject/Review.

9. Incremental Processing và Idempotency

9.1. Incremental processing

Pipeline không nên luôn reload toàn bộ dataset. Khi có batch mới, Bronze append dữ liệu mới, Silver thực hiện incremental merge và Gold cập nhật phần bị ảnh hưởng.

```
Batch 1: 100K rows
Batch 2: +50K rows
Batch 3: +50K rows

New Batch
  ↓
Bronze Append
  ↓
Silver Incremental Merge
  ↓
Gold Incremental Update
```

9.2. Batch Registry

Đề xuất bảng pipeline_batches:

```
batch_id
source
source_file
received_at
row_count
status
bronze_status
silver_status
gold_status
pipeline_run_id
processed_at
```

9.3. Idempotency

Mục tiêu là khi Airflow retry cùng một batch, trạng thái cuối của hệ thống không bị duplicate. Thiết kế sử dụng batch registry, transaction_id làm business key, deduplication và Delta MERGE.

Idempotent pipeline

Running the same input multiple times produces the same final state.

BNPL Big Data Platform

Idempotent Batch Retry Mechanism

SCALABLE • RELIABLE • DATA-DRIVEN
TURNING BNPL DATA INTO TRUSTED INSIGHTS




Figure 9: Cơ chế idempotency khi retry batch: Registry Check — Skip hoặc MERGE theo transaction_id.

10. Gold Analytics và Star Schema

Gold Analytics phục vụ BI và được mô hình hóa theo Star Schema để giảm độ phức tạp của query, hỗ trợ slicing/dicing và phù hợp Power BI.

Bảng	Vai trò
fact_bnpl_transaction	Fact table ở grain transaction.
dim_customer	Thuộc tính khách hàng tương đối ổn định.
dim_date	Date hierarchy cho time analysis.
dim_merchant	Merchant và merchant category.
dim_provider	BNPL provider.
dim_location	Customer state / geographic dimension.

credit_score tại thời điểm giao dịch nên vẫn được giữ trong fact vì credit score của cùng một customer có thể thay đổi theo thời gian.

BNPL Big Data Platform

Gold Analytics Star Schema




Figure 10: Star Schema cho Gold Analytics: fact_bnpl_transaction và các dimension tables.

11. Gold ML và Feature Engineering

11.1. ML Feature Table

Bảng ml_bnpl_features là flat feature table sẵn sàng cho Spark MLlib.

Nhóm	Feature
Raw numeric	principal_ngn, interest_rate_monthly, tenor_days, num_installments, credit_score
Raw categorical	first_time_customer, merchant_category, provider, customer_state
Derived	credit_score_band, loan_size_category
Financial derived	estimated_interest, estimated_total_payment, installment_amount
Temporal	purchase_month, purchase_quarter, purchase_day_of_week
Targets	default_30d, default_90d

11.2. Reuse feature logic

Feature engineering phải được đóng gói thành reusable Spark transformations và dùng chung cho historical training và streaming prediction. Không copy/paste hai phiên bản logic khác nhau vì sẽ tạo training-serving skew.




Figure 11: Reusable Feature Engineering dùng chung cho Batch Training và Streaming Inference.

12. Machine Learning: 30D và 90D

ML không phải trọng tâm nghiên cứu chính; mục tiêu là xây dựng use case classification rõ ràng trên nền Big Data Platform. Hệ thống huấn luyện riêng cho hai prediction horizons: default_30d và default_90d.

12.1. Models

- Logistic Regression — baseline, dễ giải thích.
- Random Forest — nonlinear ensemble.
- Gradient Boosted Trees — boosting model.

12.2. Spark ML Pipeline

```
Categorical Columns
↓
StringIndexer
↓
OneHotEncoder
↓
VectorAssembler
↓
Classifier
```

12.3. Metrics

Metric	Vai trò
Accuracy	Tỷ lệ dự đoán đúng tổng thể.
Precision	Độ chính xác trong nhóm được dự đoán Default.
Recall	Khả năng phát hiện các record thực sự Default.
F1-score	Cân bằng Precision và Recall.
ROC-AUC	Khả năng phân biệt hai lớp ở nhiều threshold.

Đặc biệt phân tích Recall của class Default và False Negative vì đây là trường hợp record thực sự default nhưng mô hình dự đoán non-default.




Figure 12: Hai nhánh training: `default_30d` và `default_90d`, mỗi nhánh so sánh LR / RF / GBT.

12.4. Model và prediction metadata

```
ml.predictions
- transaction_id
- model_name
- model_version
- prediction_horizon
- predicted_default
- default_probability
- risk_level
- prediction_timestamp
```

```

ml.model_metrics
- model_name
- model_version
- prediction_horizon
- accuracy
- precision
- recall
- f1_score
- roc_auc
- training_time_seconds
- created_at

```

13. Streaming Prediction với Kafka

Batch processing dùng để training model; streaming processing dùng để inference. Sau khi model được lưu theo version, streaming pipeline load model 30D và 90D để predict mỗi giao dịch mới.




Figure 13: Batch Training → Saved Models; Kafka Streaming → Load Saved Models → 30D/90D Prediction.

Một transaction mới có thể tạo output dạng:

```

transaction_id: TX_STREAM_000001
30D_default_probability: 0.31
90D_default_probability: 0.68
30D_prediction: NON_DEFAULT

```

```
90D_prediction: DEFAULT
risk_level: HIGH
```

Câu mô tả khi bảo vệ

Batch processing is used for analytics and model training, while Kafka streaming is used for near-real-time inference.

14. Airflow Orchestration

Airflow chịu trách nhiệm schedule, dependency, retry, logging và workflow cho batch pipeline. Spark mới là processing engine. Long-running Kafka consumer/streaming job không nên bị Airflow start lại định kỳ mỗi vài phút.





Figure 14: Airflow DAG cho batch pipeline: ingest → validate → quality → silver → features → analytics/ML → serving.

DAG logic đề xuất:

```
start
↓
ingest_data
↓
validate_bronze
↓
quality_gate
↓
bronze_to_silver
↓
data_quality_metrics
↓
feature_engineering
↓
├── build_analytics
└── build_ml_features
```

**Quy tắc triển khai**

Tất cả Spark jobs phải chạy độc lập thành công trước khi được tích hợp vào Airflow.

15. PostgreSQL và Power BI

15.1. PostgreSQL serving schemas

PostgreSQL là serving/data warehouse layer, không phải nơi lưu raw Big Data.

```

analytics.*
ml.*
data_quality.*
pipeline.*

```

15.2. Dashboard

Page	Nội dung
Overview	Total Transactions, Total BNPL Amount, Average Loan, Default Rate.
Risk Analysis	Default Rate by Credit Score, Loan Size, Provider, Merchant Category.
Customer / Geography	Default by State, First-time vs Returning, Transaction Volume by Region.
Streaming / Prediction	Transactions Received, 30D Risk Distribution, 90D Risk Distribution, Risk Level Distribution.



Figure 15: Bố cục Power BI Dashboard: Overview, Risk Analysis, Geography, Streaming Prediction.

16. Spark Cluster và Big Data Benchmark

16.1. Spark Cluster

Cấu hình phát triển ban đầu:

- 1 Spark Master
- 2 Spark Workers

Benchmark:
1 Worker vs 2 Workers

Optional:
4 Workers nếu phần cứng cho phép




Figure 16: Spark standalone cluster dùng cho development và benchmark.

16.2. Dataset sizes

Benchmark tối thiểu:

100K
500K
1M
2M

Nếu phần cứng cho phép:

5M
10M

16.3. Workload benchmark

Read
↓
Filter
↓
GroupBy
↓
Join
↓

```

Aggregation
↓
Write

```

Mỗi cấu hình nên chạy nhiều lần và dùng median runtime thay vì chỉ lấy một lần chạy. Các chỉ số chính: runtime_seconds, records_per_second. Nếu dễ thu thập từ Spark UI có thể thêm input_size, shuffle_read, shuffle_write.

Dataset	Workers	Run 1	Run 2	Run 3	Median	Throughput
100K	1	...	...	...	...	...
100K	2	...	...	...	...	...
1M	1	...	...	...	...	...
1M	2	...	...	...	...	...
2M	1	...	...	...	...	...
2M	2	...	...	...	...	...

16.4. Incremental benchmark

Ngoài worker benchmark, hệ thống cần so sánh:

- Full Reload
- Incremental Processing




Figure 17: Benchmark: dataset size × worker count và Full Reload vs Incremental Processing.

17. Docker Architecture và cấu trúc repository

17.1. Docker Compose services

```

minio
postgres

kafka
fake-bnpl-producer

spark-master
spark-worker-1
spark-worker-2
spark-streaming-job

airflow-webserver
airflow-scheduler
airflow-init

optional:
kafka-ui

```

Container-to-container communication dùng service name thay vì hard-code localhost. Cấu hình môi trường tập trung trong .env và cung cấp .env.example.




Figure 18: Docker Compose architecture cho toàn bộ BNPL Big Data Platform.

17.2. Target project structure

```
bnpl-bigdata-project/
├── docker-compose.yml
├── .env.example
├── README.md
├── airflow/
│   └── dags/
│       └── bnpl_batch_pipeline.py
├── kafka/
│   ├── producer/
│   │   └── fake_bnpl_producer.py
│   └── schemas/
│       └── bnpl_event_schema.json
├── spark/
│   └── jobs/
│       ├── 01_ingest.py
│       ├── 02_validate_bronze.py
│       ├── 03_bronze_to_silver.py
│       ├── 04_data_quality.py
│       ├── 05_feature_engineering.py
│       ├── 06_build_star_schema.py
│       ├── 07_build_ml_features.py
│       ├── 08_train_models.py
│       ├── 09_evaluate_models.py
│       └── 10_load_postgres.py
```

```

├── streaming_kafka_to_bronze.py
├── common/
│   ├── spark_session.py
│   ├── schemas.py
│   ├── validation.py
│   ├── feature_engineering.py
│   └── config.py
├── configs/
├── models/
│   ├── default_30d/
│   └── default_90d/
├── sql/
├── scripts/
├── notebooks/
├── tests/
├── dashboard/
└── docs/

```

18. Thứ tự triển khai

1. Dataset Understanding.
2. Docker + MinIO + PostgreSQL.
3. Spark Cluster.
4. Spark ↔ MinIO.
5. Bronze Batch Ingestion.
6. Schema Validation.
7. Data Quality Gate.
8. Bronze → Silver Delta.
9. Data Quality Metrics.
10. Feature Engineering.
11. Gold Analytics.
12. Star Schema + PostgreSQL.
13. Power BI.
14. Gold ML.
15. Train 30D + 90D Models.
16. Evaluate + Save Models.
17. Airflow Integration.
18. Incremental Processing.
19. Batch Registry + Idempotency.
20. Kafka.
21. Fake Data Producer.
22. Spark Structured Streaming.
23. Kafka → Bronze.
24. Streaming Prediction.
25. Benchmark.

- 26. Testing.
- 27. Documentation.

Thứ tự ưu tiên

Batch pipeline phải ổn định trước khi đưa Kafka streaming vào. Spark jobs phải chạy độc lập trước khi tích hợp Airflow.

19. Mức độ ưu tiên

Priority	Nội dung
P0 — Must Have	Docker, MinIO, Spark, Bronze/Silver/Gold, Quality Gate, PostgreSQL, Star Schema, Airflow, Power BI, MLlib, 30D + 90D.
P1 — Strongly Recommended	Kafka, Fake Producer, Structured Streaming, Delta Silver/Gold, Incremental Processing, Batch Registry, Idempotency, Benchmark.
P2 — Optional	Kafka UI, External API, CI/CD, Advanced Monitoring.

20. Kịch bản demo cuối môn

- 28. Chạy docker compose up -d.
- 29. Mở Airflow và trigger batch DAG.
- 30. Historical data đi vào Bronze.
- 31. Hiện thị Schema Validation / Data Quality Gate.
- 32. Hiện thị Silver và Gold data.
- 33. Hiện thị Star Schema và PostgreSQL serving tables.
- 34. Mở Power BI dashboard.
- 35. Hiện thị Spark cluster / Spark UI.
- 36. Hiện thị metrics của 30D và 90D models.
- 37. Khởi động fake BNPL producer.
- 38. Quan sát event được gửi vào Kafka.
- 39. Spark Structured Streaming consume event và persist vào Bronze.
- 40. Streaming pipeline tạo features và load saved models.
- 41. Hiện thị 30D/90D prediction.
- 42. Prediction được ghi vào PostgreSQL và phản ánh trên dashboard.
- 43. Hiện thị benchmark 1 worker vs 2 workers và full vs incremental.

End-to-End Demo Flow: Batch Pipeline to Kafka Streaming Prediction




Figure 19: End-to-end demo flow từ Batch Pipeline đến Kafka Streaming Prediction.

21. Deliverables và Definition of Done

21.1. Deliverables

- Source code repository.
- Docker infrastructure / Docker Compose.
- Airflow DAG.
- Spark distributed batch pipeline.
- Kafka fake producer và streaming pipeline.
- Bronze / Silver / Gold data.
- Rejected / quarantine records.
- Data Quality metrics.
- PostgreSQL warehouse.
- Star Schema.
- ML Feature Table.
- 30D và 90D models + metrics.
- Prediction serving tables.
- Power BI dashboard.

- Incremental pipeline + batch registry.
- Scalability benchmark.
- Architecture documentation.
- Demo video.
- Final report.

21.2. Definition of Done

- Docker infrastructure khởi động thành công.
- Spark cluster hoạt động.
- Spark đọc/ghi được MinIO.
- Historical data được ingestion vào Bronze.
- Bronze record được validation.
- Invalid records được giữ ở rejected/quarantine.
- Valid records tới Silver Delta.
- Gold Analytics được build.
- Star Schema được load vào PostgreSQL.
- Power BI-ready tables/views tồn tại.
- Gold ML feature table tồn tại.
- 30D models được train/evaluate.
- 90D models được train/evaluate.
- Models được lưu theo version metadata.
- Airflow orchestrate được batch workflow.
- Incremental load hoạt động.
- Retry cùng batch không tạo duplicate.
- Kafka khởi động đúng.
- Fake producer gửi được BNPL transactions.
- Spark Structured Streaming consume Kafka events.
- Streaming raw data được persist vào Bronze.
- Streaming transaction nhận được 30D/90D predictions.
- Predictions được ghi PostgreSQL.
- Data Quality metrics có thể truy xuất.

- Spark benchmark có thể tái lập.
- README và docs phản ánh đúng hệ thống thực tế.

22. Giới hạn và rủi ro kỹ thuật

Rủi ro / giới hạn	Cách xử lý
Dataset là synthetic	Chỉ đánh giá kiến trúc/methodology, không suy rộng thành kết luận thực tế cho toàn bộ Nigeria.
Máy local giới hạn RAM/CPU	Giữ Spark cluster nhỏ; benchmark có kiểm soát; scale tối đa theo phần cứng.
Airflow + Spark + Kafka + MinIO nhiều service	Build theo phase; kiểm tra từng job độc lập trước orchestration.
Schema thay đổi	Expected schema tập trung + compatibility check + controlled evolution.
Retry gây duplicate	Batch registry + business key + Delta MERGE + idempotency.
Training-serving skew	Tái sử dụng cùng feature transformation cho batch và streaming.
Power BI realtime hạn chế	Near-real-time serving qua PostgreSQL; ưu tiên demo ổn định hơn ultra-low latency.

23. Kết luận kiến trúc

Scope cuối cùng tạo thành một BNPL Big Data Platform hoàn chỉnh nhưng vẫn phù hợp đồ án học phần. Historical data được xử lý theo batch để tạo analytics và huấn luyện mô hình; fake transaction được truyền qua Kafka và xử lý bởi Spark Structured Streaming cho near-real-time inference. Medallion Architecture giúp phân tách raw, trusted và business-ready data. Data Quality, schema validation, incremental processing và idempotency giúp pipeline mang tính production-oriented hơn, trong khi Spark benchmark chứng minh yếu tố distributed processing và scalability.

Kiến trúc cuối cùng bao phủ: Batch + Streaming + Data Lake + Distributed Processing + Data Quality + Data Warehouse + Orchestration + Machine Learning + BI + Scalability Benchmark.

Mô tả một câu khi thuyết trình

The project builds an end-to-end BNPL Big Data platform supporting batch analytics and model training, while Kafka and Spark Structured Streaming process simulated transactions for near-real-time 30-day and 90-day default-risk prediction.

Tài liệu tham khảo

- [1] Electric Sheep Africa. Africa Synth Banking BNPL Nigeria dataset, Hugging Face.
- [2] Apache Kafka Documentation. Introduction / Event Streaming.

[3] Apache Spark Documentation. Structured Streaming and Kafka Integration.

[4] Delta Lake Documentation. ACID transactions, schema enforcement, time travel and MERGE.

[5] Apache Airflow Documentation. Workflow orchestration.